



Análisis del rendimiento en el algoritmo de machine learning que emula ondas ERP P300 usado en un experimento con interfaces cerebro computador en pacientes con ELA (Esclerosis Lateral Amiotrófica).

Alumno: Alexander Chavez Montaña

Supervisor: Rodrigo Ramele

Proyecto final

Especialización en Ciencia de datos

Índice

Lista de figuras	III
1. Introducción	1
1.1. Esclerosis Lateral Amiotrófica.	2
1.2. El P300 Speller y el oddball paradigm (paradigma del bicho raro).	2
1.3. ¿Qué es un ERP (Event Related Potential)?.	3
1.4. EEG.	4
2. Estado del arte	6
3. Definición del problema	8
4. Alcance	9
5. Hipótesis	10
6. Objetivos	11
6.1. General.	11
6.2. Específicos.	11
6.2.1.	11
6.2.2.	11
6.2.3.	11
7. Análisis Exploratorio de Datos (EDA)	13
7.1. Los datasets y las señales.	13
7.1.1. El Template del ERP.	13
7.1.2. Datasets de P300.	13
8. Materiales y métodos	15
9. Resultados y conclusiones	17
9.1. Variaciones en amplitud.	17
9.2. Variación en el tiempo.	18

10.Resumen	20
11.Agradecimientos	21
Bibliografía	22

Lista de figuras

1.1. Paradigma del Oddball.	3
1.2. Plantilla ERP obtenida a partir del conjunto coherente punto a punto promedio de las señales del sujeto número ocho del dataset público BNCI Horizon 008-2014. La plantilla tiene una duración de 1 s, que es 256 puntos de muestra, y los ocho canales se superponen con diferentes colores. El componente P300 es el pico de amplitud mas alto, se puede visualizar entre las muestras 150 y 200.	4
1.3. Posicionamiento de los electrodos.	4
1.4. Canales del electroencefalograma obtenidos del paciente P300S01 del dataset público P300 Dataset ITBA: Fz, Cz, Pz, Oz, P3, P04, P07 y P08.	5
7.1. Canales del electroencefalograma obtenidos del paciente P300S01 del dataset público P300 Dataset ITBA, incluidas las marcas del experimento, t-stim y t-type, que proporcionan información de la posición donde están situados los eventos.	14
9.1. Comparativa de la función gaussiana (color naranja, línea punteada) con el template ERP.	17
9.2. Comparativa del Accuracy de los cuatro EEG de pacientes pavisos en una secuencia de intensificación de la amplitud de la onda inyectada.	18
9.3. Comparativa del Accuracy de los cuatro EEG de pacientes pavisos en una secuencia de desplazamiento en fase de la onda inyectada.	19

1. Introducción

La electroencefalografía es una de las herramientas clínicas que, a lo largo de las últimas décadas, se ha convertido en uno de los principales métodos para obtener imágenes en tiempo real del comportamiento cerebral de manera no invasiva, portátil y móvil más usado en el ambiente médico (Hartman (2005)). Dentro de la electroencefalografía tenemos un conjunto de ondas con distintas características que varían en sus propiedades físicas como amplitud o frecuencia, como también en el origen y la ubicación en las distintas zonas del cerebro. La onda P300 se obtiene de ubicar un canal en el lóbulo parietal y su comportamiento es reactivo debido a estímulos esperados pero infrecuentes relacionados con actos cognitivos.

Sin embargo, la electroencefalografía está expuesta a alteraciones no deseadas en sus resultados, ya que, por más controlado, preciso y consistente que sea el ambiente donde se realiza el experimento o la toma de muestra, estaremos sujetos a factores fuera de nuestro control. Esta problemática se suele afrontar generando ambientes de pruebas donde se pueda recrear la situación con la mayor fidelidad posible. Los experimentos pasados y éste trabajo integrador se cimentan en la base de datasets sintéticos, artificiales, con los que se simulan respuestas de ondas ERP P300 a partir de electroencefalogramas reales, con resultados previamente conocidos, a fin de trabajar en la performance de algoritmos que logren resultados con mejoras en el tiempo.

Los métodos y los procedimientos cuantitativos para automatizar la decodificación de ondas EEG como la P300 se basa en EEG no invasivo (Guger (2017)) y ya existen estudios donde profundizan sobre distintos tratamientos en la onda P300. Tales son los casos de dos investigaciones como *Histogram of Gradient Orientations of Signal Plots Applied to P300 Detection* (Ramele R. (2019)), *Improving longitudinal P300-BCI performance for people with ALS using a data augmentation and jitter correction approach* (Zisk A. (2021)), *Dynamic time warping-based transfer learning for improving common spatial patterns in brain-computer interface* (Azab A. (2020)) ó *A Fast and Reliable Method for Simultaneous Waveform, Amplitude and Latency Estimation of Single-Trial EEG/MEG Data* (W. (2012)).

Sin embargo, los métodos de la decodificación de señales, basadas en detección de formas

de onda, y además con algoritmos de machine learning son relativamente escasos.

En este trabajo se dará continuidad a la investigación realizada en los experimentos descritos en el artículo *EEG Waveform Analysis of P300 ERP with Applications to Brain Computer Interfaces* (Ramele (2018)) en pacientes con ELA (Esclerosis Lateral Amiotrófica): en éste trabajo se realiza un análisis exploratorio de electroencefalogramas llamados pasivos; pacientes que participaron del experimento pero desconociendo las reglas de interacción con el speller, explicado más adelante en profundidad. En una etapa posterior se “inyectan” potenciales P300 en los lugares donde sabemos de antemano suceden los eventos, y realizamos modificaciones en las propiedades de las ondas que arrojan distinta performance para permitirnos obtener mejoras en la preconfiguración del algoritmo.

1.1. Esclerosis Lateral Amiotrófica.

La esclerosis lateral amiotrófica o ELA, es una enfermedad degenerativa de las neuronas en el cerebro, el tronco cerebral y la médula espinal que controlan el movimiento de los músculos voluntarios. En la ELA, las células nerviosas (neuronas) motoras se desgastan o mueren y ya no pueden enviar mensajes a los músculos. Con el tiempo, esto lleva a debilitamiento muscular, espasmos e incapacidad para mover los brazos, las piernas y el cuerpo. La afección empeora lentamente. Cuando los músculos en la zona torácica dejan de trabajar, se vuelve difícil o imposible respirar. En pacientes con ELA de etapas intermedias y avanzadas, es necesario el uso de dispositivos tecnológicos para la comunicación, como el P300 Speller.

1.2. El P300 Speller y el oddball paradigm (paradigma del bicho raro).

El P300 Speller es un dispositivo que conforma uno de las BCI (Brain Computer Interfaces) más usados en este tipo de aplicaciones. Su funcionamiento se acoge al paradigma del bicho raro: al usuario/paciente se le presenta una matriz de caracteres de 6 por 6 (ver figura) de manera intermitente, sucesiva y aleatoria. La tarea del usuario/paciente será enfocar su atención en los caracteres de una palabra prescrita por el investigador; es decir, un

carácter a la vez. Cuando éstas contienen el carácter deseado (es decir, una fila particular y una columna determinada) se registra el potencial evocado P300 en el registro del EEC. Es un dispositivo comunmente usado en investigación, (F. Velasco-Álvarez (2019)).




Figura 1.1: Paradigma del Oddball.

1.3. ¿Qué es un ERP (Event Related Potential)?.

De forma paralela, es necesario explicar qué es una señal P300. La palabra evocada es clave: en medicina, se refiere a una actividad que puede ser detectada sincrónicamente después de una cantidad específica de tiempo después del inicio de un estímulo. Si estamos a la espera de que un computador nos dé una señal visual y nos la da, en nuestro cerebro ocurre un evento de este tipo. En términos médicos es una *actividad inducida*.

La onda P300 es entonces, una señal en el cerebro con amplitud positiva relacionada con eventos. Para esta investigación, los eventos serán aquellos provocados bajo *el paradigma del bicho raro*: El sujeto detecta un estímulo objetivo ocasional en un tren regular de estímulos estándar.

La onda P300 solo ocurre si el sujeto participa activamente en la tarea de detectar los objetivos. Su amplitud varía con la improbabilidad de los objetivos. Su latencia varía con la dificultad de discriminar el estímulo objetivo de los estímulos estándar. Una latencia pico típica cuando un sujeto adulto joven hace una discriminación simple es de 300 ms.

En pacientes con capacidad cognitiva disminuida, el P300 es más pequeño y más tardío que en sujetos normales de la misma edad.




Figura 1.2: Plantilla ERP obtenida a partir del conjunto coherente punto a punto promedio de las señales del sujeto número ocho del dataset público BNCI Horizon 008-2014. La plantilla tiene una duración de 1 s, que es 256 puntos de muestra, y los ocho canales se superponen con diferentes colores. El componente P300 es el pico de amplitud mas alto, se puede visualizar entre las muestras 150 y 200.

El ERP P300 Puede tener una duración de 400ms y su amplitud puede alcanzar los 10 μ V (Rao (2013)). Se desconoce el origen intracerebral de la onda P300 y su papel en la cognición no se comprende con claridad. El P300 puede tener múltiples generadores intracerebrales, con el hipocampo y varias áreas de asociación de la neocorteza contribuyendo al potencial registrado en el cuero cabelludo. La onda P300 puede representar la transferencia de información a la conciencia, un proceso que involucra muchas regiones diferentes del cerebro (TW (1992)).

1.4. EEG.

El electroencefalograma obtenido se puede observar de dos maneras distintas: Una con cada una de sus componentes por separado, y la otra como una sola señal compuesta. Se utilizan en las ubicaciones Fz, Cz, Pz, Oz, P3, P4, PO7 y PO8 según el sistema internacional 10-20 para la colocación de los electrodos extracraneales.




Figura 1.3: Posicionamiento de los electrodos.

La referencia se establece en el lóbulo de la oreja derecha y la tierra está preestablecida como la posición AFz. La frecuencia de muestreo se establece en 250 Hz.

En la siguiente gráfica se puede ver en detalle cada uno de los canales del electroencefalograma:




Figura 1.4: Canales del electroencefalograma obtenidos del paciente P300S01 del dataset público P300 Dataset ITBA: Fz, Cz, Pz, Oz, P3, P4, P7 y P8.

2. Estado del arte

Los experimentos descritos en el artículo *EEG Waveform Analysis of P300 ERP with Applications to Brain Computer Interfaces* (Ramele (2018)) sirvieron como base para este proyecto. Si bien es necesario revisar todo el artículo en mención, damos un alcance y limitaciones de este trabajo específicamente capítulo 5; el estado del arte es entonces, el experimento descrito en el artículo.

En el capítulo 3 del artículo; *Materiales y Métodos*, específicamente el punto 3.6; *Protocolo experimental*, dan la información necesaria para enmarcar los detalles del experimento cuyo objetivo central es el de evaluar el rendimiento de los algoritmos que reconocen la forma de onda P300, obtenida después de promediar segmentos de señal.

El rendimiento es evaluado mediante el procesamiento de un conjunto de datos pseudo-reales en dos modalidades, una llamada pasiva y otra activa, en alusión a la información de la que los pacientes disponen al momento del experimento. **Las pruebas de rendimiento de este trabajo final integrador complementan las realizadas en la modalidad pasiva, al realizar modificaciones en latencia y amplitud del componente P300 de distintas magnitudes.** Los experimentos se realizan mediante la evaluación fuera de línea de la identificación del personaje de una aplicación BCI Speller basada en Visual P300.

El paradigma BCI usado en los experimentos del artículo es el Farwell and Donchin P300 Speller (Farwell (1988)). En él, se usa un dispositivo de traducción de pensamientos donde envía comandos a una computadora en forma de letras seleccionadas, similar a escribir en un teclado virtual. El paradigma y el P300 Speller están descritos en el capítulo 9.2 de este trabajo.

La generación de flujo de EEG, es decir, la recopilación de la señal de los pacientes mencionada en el punto 3.6.1 del artículo, describe su estado de salud, la cantidad de pacientes, edad, de acuerdo a las normativas dictadas por la organización mundial de la salud. Incluso la disposición del paciente con respecto al dispositivo y las ubicaciones de los electrodos junto con la referencia, además de los dispositivos utilizados y la frecuencia de muestreo de la onda establecida en 250Hz. Además, el protocolo experimental está compuesto por una cantidad de ensayos específica con el fin de deletrear una cantidad de

palabras con letras predefinidas. Tienen secuencias para la matriz de 6 columnas por 6 filas con intervalos y pausas establecidos.

El preprocesamiento de la señal son las bases para la generación de las ondas que serán el objeto de estudio de este proyecto: se extraen, se filtran para eliminar ruido y también se descartan variaciones que estén por fuera de los parámetros esperados. El experimento dura alrededor de 1400s y el resultado final es una traza EEG con 4200 secciones marcadas donde 3500 de ellos están etiquetados como verdaderos y los 700 restantes como falsos. Esta información, al estar estandarizada, se almacena en formatos preestablecidos que pueden ser usados con la librería de python MNE descrita en el capítulo 8.

En cuanto a la participación de las personas en el experimento, a cuatro de los ocho se les indica que miren pasivamente la pantalla parpadeante sin centrarse en alguna letra en particular. No reciben ninguna información adicional en la pantalla. Ninguno de ellos tiene o tuvo alguna experiencia con un dispositivo BCI. Se entrega un cuestionario al final del experimento con preguntas sobre cómo se sintió el participante durante el mismo, sin dar más detalles. Los cuatro participantes restantes realizan una tarea de ortografía en la que el monitor de la computadora resalta la letra objetivo, que es la que el sujeto necesita enfocar. A lo largo de la duración de la prueba, la letra objetivo actual se informa en la parte inferior de la pantalla.

La modalidad activa no será tenida en cuenta en este trabajo.

La modalidad pasiva consiste en que, para la mitad de los pacientes, se realiza un ensamblado de la traza EEG final: se toman plantillas reales de un ERP P300 de un conjunto de datos público y se superponen con el la traza EEG generado en dichos pacientes, los cuales fueron aquellos de los que no estaban informados con detalle del experimento.

3. Definición del problema

Este trabajo consiste en el análisis de datos pseudo-reales y sintéticos de señales compuestas por electroencefalogramas y potenciales P300 inyectados de manera artificial. A estos datos les son aplicados algoritmos de *machine learning* que arrojaron resultados con métricas que permiten obtener parámetros de rendimiento. Se hizo este mismo procedimiento alterando la amplitud y la fase de dichas ondas compuestas, para así verificar el rendimiento en distintas magnitudes.

En este tipo de estudios, se presenta la problemática al tomar registros de señales compuestas donde dichas señales dependen de una acción cognitiva, en este caso vistas en el potencial P300; no sabemos con certeza si dicha acción cognitiva realmente se ejecutó en la persona. Estas señales son conocidas como *Null-signals* y, utilizando el procedimiento de modificar artificialmente la amplitud y fase de manera controlada, para luego testear los algoritmos aplicados en este tipo de señales compuestas, se pretende eliminar la problemática de las *Null-signals*.

4. Alcance

El presente trabajo está enfocado únicamente al testeo del algoritmo destinado a generar una onda compuesta de manera sintética. De los potenciales evocados P300, registrados con la interfaz cerebro computador BCI2000 (Schalk et al. (2004)), y disponibles en los datasets de BNCI Horizon, 008-2014, extraeremos el Template del ERP. Y del segundo dataset, el P300-Dataset, que está conformado por 8 EEGs, se tomarán sólo aquellos que pertenecen al segundo grupo cuya modalidad es pasiva: P300S01,02,03,06.

Se reconstruirán las señales sintéticas bajo el procedimiento pre-establecido en el artículo *EEG Waveform Analysis of P300 ERP with Applications to Brain Computer Interfaces*(Ramele (2018)). Se espera que, con los resultados obtenidos al modificar deliberadamente las propiedades de la onda, podamos tener un espectro de respuestas que nos permitan proponer mejoras para trabajos posteriores. No se realizarán toma de muestras ni se realizarán experimentos donde estén involucrados pacientes nuevos o electroencefalogramas adicionales.

5. Hipótesis

Mediante la composición de señales sintéticas a partir de dos datasets: el BNCI Horizon, 008-2014, y el P300-Dataset, y variaciones en la amplitud y latencia de dichas ondas, se pretende encontrar mejorías en el rendimiento del algoritmo predictivo que identifica si hay o no un disparo de P300, a través de métricas como *precision*, *recall* y *f1-score*.

6. Objetivos

6.1. General.

Realizar modificaciones en amplitud y fase de señales de electroencefalografía conformadas de manera sintética con portenciales P300 inyectados artificialmente, para ser procesados con algoritmos de *machine learning* y que nos arroje un espectro de respuestas que visualicen el rendimiento en función de dichas propiedades de las señales.

6.2. Específicos.

6.2.1.

Realizar un recorrido en la mayor cantidad de información disponible sobre los objetos de estudio: por un lado, el potencial de eventos evocado P300. Por otro, electroencefalogramas de pacientes sanos y pacientes con ELA (Esclerosis Lateral Amiotrófica), y por último todo el conjunto de señales que se obtienen producto de una interfaz cerebro computador (BCI por sus siglas en inglés) vinculado a un instrumento de comunicación llamado P300 speller.

6.2.2.

Completar un análisis exploratorio de datos (EDA por sus siglas en inglés) con los datasets usados en los experimentos, a través de las herramientas computacionales disponibles: librerías de python especializadas en el manejo de datos y electroencefalografía.

- BNCI Horizon 2020: 8. Speller P300 with ALS patients (008-2014).
- ITBA. P300 dataset of 8 healthy subjects.

6.2.3.

Regenerar las señales sintéticas pseudoreales: esto se logrará tomando, por una parte, el Template del ERP, y por otra, electroencefalogramas de aquellos pacientes del experimento en el artículo *EEG Waveform Analysis of P300 ERP with Applications to Brain Computer*

Interfaces(Ramele (2018)) cuya modalidad sea pasiva. Una vez creado el dataset sintético, presentar todos los resultados obtenidos de las modificaciones en las propiedades de la onda compuesta y proponer mejoras en la preconfiguración del algoritmo.

7. Análisis Exploratorio de Datos (EDA)

7.1. Los datasets y las señales.

Ya mencionado anteriormente, los electroencefalogramas que fueron usados son *Matlab files*: archivos de extensión .mat en versiones con funcionalidades de almacenamiento de *arrays* de n dimensiones de hasta 100.000.000 elementos por arreglo y 2^{31} bytes por variable.

El dataset de BNCI Horizon, el 008-2014, contiene un grupo completo de potenciales evocados P300 registrados con la interfaz cerebro computador BCI2000 (Schalk et al. (2004)). De éste dataset obtendremos el Template del ERP. El otro, el P300-Dataset, está conformado por 8 EEGs de donde se extraerán algunos para realizar las pruebas del algoritmo. Todos los datasets están basados en el paradigma Farwell y Donchin (Farwell (1988)) mencionado en el punto 1.2. Las señales usadas en este trabajo serán descritas a continuación:

7.1.1. El Template del ERP.

Si bien la descripción de qué es un ERP está en el punto 1.3, es importante mencionar que éste ERP se extrae artificialmente del dataset de BNCI Horizon (008-2014) para ser “inyectado” a una señal EEG del P300-Dataset con el fin de crear una señal sintética que nos permita realizar las modificaciones de latencia y amplitud en donde quede empalmado dicho ERP. El proceso está descrito en el punto 1.5.

7.1.2. Datasets de P300.

El P300-Dataset está conformado por 8 EEGs distribuidos en dos grupos según la modalidad del experimento: pasivos P300S01,02,03,06 y activos P300S04, 05, 07 y 08. Este trabajo se enfoca en los pacientes pasivos: las trazas de EEG donde se superponen las pantallas ERP son de los pacientes que **no se enfocan en ninguna letra en particular**. Todo está allí, excepto el componente P300 ERP. Es por esto que se utiliza la información de marcadores para localizar los segmentos verdaderos donde se debería encontrar el P300, y esas ubicaciones de tiempo se utilizan para superponer la forma de onda de ERP extraída.

El archivo *.mat* que contiene las señales obtenidas no solamente contiene las señales del electroencefalograma, sino las marcas del experimento. Es con ellas que se identifican dónde se encuentran los tiempos en donde se han mostrado los caracteres. El tratamiento del dataset está basado principalmente en la librería MNE de Python usada ampliamente en este tipo de investigaciones (Gramfort A. (2013)).




Figura 7.1: Canales del electroencefalograma obtenidos del paciente P300S01 del dataset público P300 Dataset ITBA, incluidas las marcas del experimento, t-stim y t-type, que proporcionan información de la posición donde están situados los eventos.

8. Materiales y métodos

La estructura de este trabajo integrador está pensada en función de los objetivos. Primero se ofrecerá un análisis exploratorio de datos, no solamente de los datos en sí, sino también del contexto del experimento realizado el ITBA mencionado anteriormente. Este análisis exploratorio contendrá los datasets usados en los experimentos:

- BNCI Horizon 2020: 8. Speller P300 with ALS patients (008-2014).
- ITBA. P300 dataset of 8 healthy subjects.

El contenido de estos datasets está descrito en el capítulo 7. En segundo lugar, hubo una preparación de los datos para ser modelados, complementado con las herramientas computacionales disponibles: librerías de python especializadas en el manejo de datos y electroencefalografía.

En tercer lugar, se aplicará el modelo con las distintas variaciones en las propiedades de la onda compuesta de manera sintética. Y en cuarto y último lugar, se mostrarán los gráficos de los resultados obtenidos de las modificaciones más representativas en las propiedades de la onda compuesta, acompañados con una propuesta de mejoras en la preconfiguración del algoritmo.

Las herramientas y/o librerías usadas en este proyecto se pueden clasificar en dos; matemáticas y de electroencefalografía, todas concentradas en el lenguaje de programación Python. Los electroencefalogramas que fueron usados son Matlab files: archivos de extensión .mat en versiones con funcionalidades de almacenamiento de arrays de n dimensiones de hasta 100.000.000 elementos por arreglo y 2^{31} bytes por variable, (*Mathworks* (2023))

Dentro de las librerías matemáticas se encuentran **NumPy** para permitir el manejo de arreglos grandes y multidimensionales, **SciPy** con módulos para optimización , álgebra lineal , integración , interpolación , funciones especiales , FFT , procesamiento de señales e imágenes, entre otros, **Matplotlib** y **Seaborn** para visualización de los datos, y **Pandas** para la manipulación y análisis tanto de los archivos usados como fuentes de datos como para los distintos procesos intermedios en el análisis exploratorio. La librería destinada al machine learning es **Scikit-learn**: dispone de algoritmos de clasificación, regresión y agrupamiento , que incluyen support vector machine, random forest, k -means y DBSCAN.

Tiene la versatilidad para interactuar con el resto de librerías mencionadas anteriormente.

Por otra parte se usó la librería *MNE*: permite la exploración, visualización y análisis de datos neurofisiológicos humanos: MEG, EEG, sEEG, ECoG, NIRS, entre otros.

La plantilla ERP viene con toda la información disponible, no solo para este tipo de experimentos, sino para otras aplicaciones. La información está en crudo. La frecuencia de muestreo es de 256, se bajó a 250Hz.

Después se extrajo la señal con todos los canales del electroencefalograma, y por separado la matriz que contiene las marcas del experimento que proporcionan la información de dónde están situados los eventos.

Una vez extraídas estas señales, se organizan para ser procesadas ya con la librería *MNE*, encargada de la obtención de los eventos, en donde se toman todos los segmentos sincronizados con las estimulaciones que corresponden con un hit/nohit, calculando la señal promedio.

Una vez obtenidos los eventos, se usó un modelo de regresión logística para obtener los correspondientes reportes de clasificación y matrices de confusión, y posteriormente llegar a las métricas del modelo.

Todos estos pasos están dentro de un ciclo general que permitió, con uno de los cuatro encefalogramas, realizar todos estos procesos con diferentes valores de amplitud y fase, acumulando los resultados que están en el siguiente capítulo.

9. Resultados y conclusiones

De la señal original conformada por el electroencefalograma y la inyección del *template ERP*, basados en la información en *t-flash*, se creó un nuevo dataset cuyos elementos son no son mas que *copias* de la señal procesada original, con variaciones en la amplitud y fase, definidos como vectores dentro del código.

A medida que se recorren los vectores mencionados, se ejecuta una regresión logística y se evalúa la métrica *precision*, tanto para los *hit* como para los *nohit*, que son las marcas donde se identifica si hay o no un disparo de P300.

El experimento se realizó con las cuatro señales correspondientes a los pacientes denominados pasivos, arrojando el mismo comportamiento en las modificaciones propuestas en este trabajo.

El punto de referencia para realizar la comparativa de los resultados se hizo usando una función de tipo gaussiana con un periodo y amplitud similar al template ERP:




Figura 9.1: Comparativa de la función gaussiana (color naranja, línea punteada) con el template ERP.

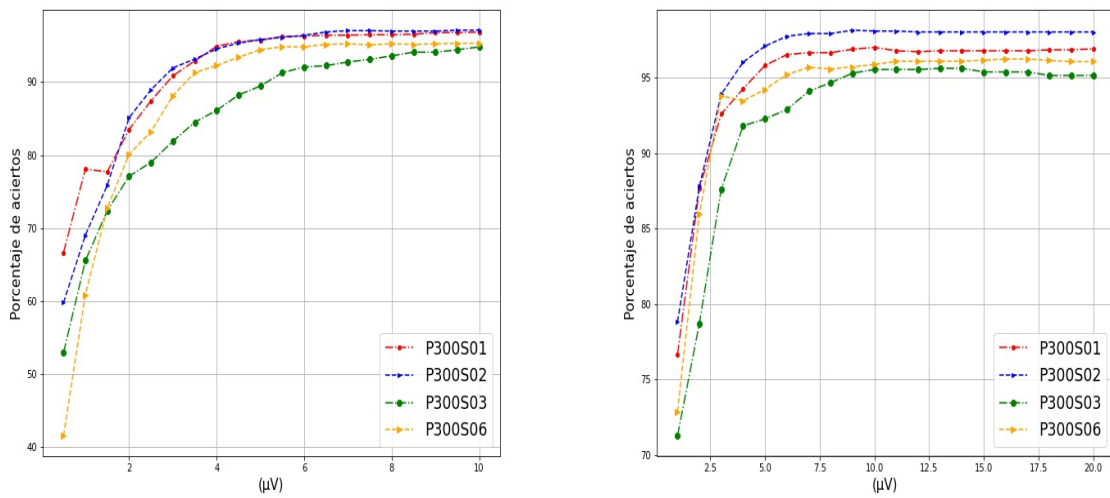
Los parámetros de la función gaussiana elegidos son de una *media* = 0, una *desviación estándar* de 30 y una *amplitud* de 700uV

9.1. Variaciones en amplitud.

Se realizaron pruebas con distintos vectores de distintos tamaños, que generaron modificaciones en la amplitud del orden de los micro Voltios. **Para alteraciones en amplitud**, y tanto en disparos de hit como en nohit, existen intervalos en donde se

mejoran los resultados y que el algoritmo se estabiliza aun cuando se pueda continuar realizando variaciones. Esto sucede porque la amplitud es una característica de la señal que, si bien puede aportar mejoras, los disparos de *hit/nohit* son fenómenos en la señal t-flash que suceden en el tiempo.

La calidad del modelo, dada por la métrica de *precision*, presenta mejoras cuando se varía la amplitud, pero se estanca cuando supera un umbral. La amplitud no afecta los resultados después de los 5 μV .



(a) Secuencia de intensificación de amplitud del template ERP insertado. (b) Secuencia de intensificación de amplitud de la función gaussiana.

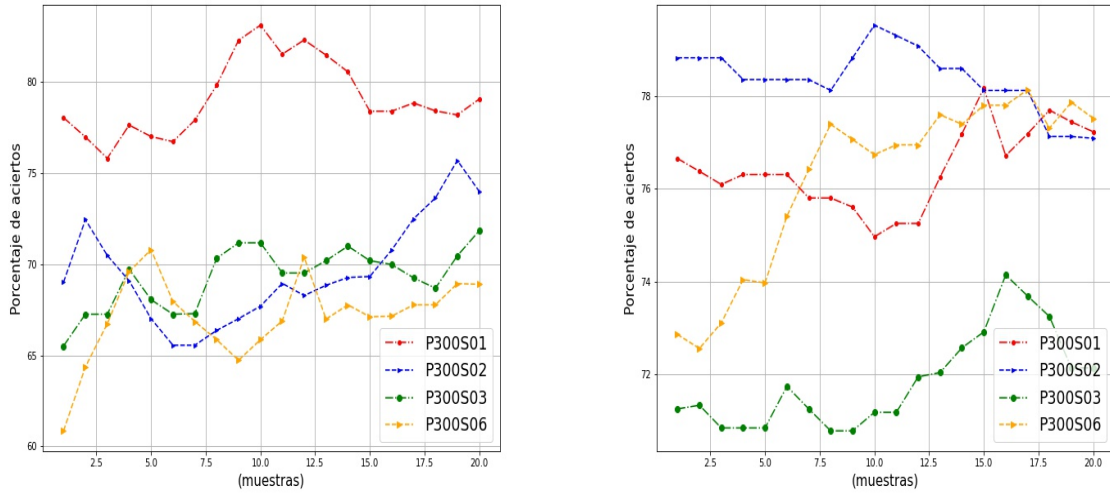
Figura 9.2: Comparativa del Accuracy de los cuatro EEG de pacientes pavisos en una secuencia de intensificación de la amplitud de la onda inyectada.

Cabe destacar que, al reemplazar el template ERP por una función gaussiana, y realizar el mismo experimento de variar la amplitud de la señal inyectada; no se observan mayores cambios en el comportamiento, tal y como podemos observar en la gráfica 9.2(b).

9.2. Variación en el tiempo.

Misma metodología que el punto 9.1: se generaron distintos vectores de distintos tamaños que permitieron genera desfase en el tiempo y cuya unidad es en muestras. Las métricas arrojan que, **para alteraciones en el tiempo (muestras)**, no necesariamente ocurren mejoras en el rendimiento, ni tampoco comportamientos similares entre disparos *hit/nohit*.

Es importante tenerlo en cuenta, ya que, es el total de la predicción la que impacta en el resultado. El desfase de las ondas modifica de manera directa y con altos márgenes en la predicción del algoritmo:



(a) Secuencia de desplazamiento en fase del template ERP insertado. (b) Secuencia de desplazamiento en fase de la función gaussiana.

Figura 9.3: Comparativa del Accuracy de los cuatro EEG de pacientes pavisos en una secuencia de desplazamiento en fase de la onda inyectada.

Continuando con la misma metodología usada en el caso de las alteraciones en amplitud, al reemplazar el template ERP por una función gaussiana, y realizar desplazamientos en el tiempo; los resultados muestran cambios, pero no significativos en los órdenes de magnitud que se están investigando. Es el caso, por ejemplo, del paciente P300S01, representado en las gráficas en color rojo: cuando el desplazamiento ocurre con el template ERP inyectado, el porcentaje de aciertos está en el intervalo del 75 al 85. Al realizar la misma prueba, pero con una señal gaussiana inyectada y en reemplazo del template ERP, dicho porcentaje de aciertos oscila entre 75 y 78.

10. Resumen

Este trabajo complementa la investigación previa realizada en los experimentos descritos en el artículo EEG Waveform Analysis of P300 ERP with Applications to Brain Computer Interfaces (Ramele (2018)) en pacientes con ELA (Esclerosis Lateral Amiotrófica): parte del resultado de dicho trabajo fue la de investigar algoritmos de machine learning que emulan ondas ERP P300: tomamos ese trabajo como punto de partida para realizar un análisis exploratorio tanto del objeto de estudio como de las herramientas computacionales disponibles, para luego realizar un abanico de pruebas que arrojen distinta performance y nos permitan proponer mejoras en la preconfiguración de dicho algoritmo.

11. Agradecimientos

A mis dos emes: Macu y Marco.

Bibliografía

- Azab A., Hamed Ahmadi H., M. L. A. M. (2020). Dynamic time warping-based transfer learning for improving common spatial patterns in brain-computer interface. *Journal of Neural Engineering*, Volume 17, Number 1.
- F. Velasco-Álvarez, S. S.-R. (2019). Uma-bci speller, a p300-based spelling tool. *Departamento de Tecnología Electrónica, Universidad de Málaga, Málaga*.
- Farwell, L. A., . D.-E. (1988). Talking off the top of your head: toward a mental prosthesis utilizing event-related brain potentials. *National library of medicine*.
- Gramfort A., L. M. (2013). Meg and eeg data analysis with mne-python. *Front. Neurosci., Sec. Brain Imaging Methods*, Volume 7.
- Guger, C.; Allison, B. L.-M. (2017). *Introduction. In Brain Computer Interface Research: A State of the Art Summary 6*. Springer.
- Hartman, A. (2005). *Atlas of EEG Patterns*. Lippincott Williams Wilkins.
- Mathworks (2023). Versiones de archivos mat.
- Ramele, R.; Villar, A. S.-J. (2018). Eeg waveform analysis of p300 erp with applications to brain computer interfaces: Computer engineering department, instituto tecnológico de buenos aires (itba).
- Ramele R., Villar A.J., S. J. (2019). Histogram of gradient orientations of signal plots applied to p300 detection. *Frontiers in Computational Neuroscience*.
- Rao, R. P. N. (2013). *Brain-Computer Interfacing: An Introduction*. Cambridge University Press.

- Schalk, G., McFarland, D. J., Hinterberger, T., Birbaumer, N., and Wolpaw, J. R. (2004). Bci2000: a general-purpose brain-computer interface (bci) system. *IEEE Transactions on biomedical engineering*, 51(6):1034–1043.
- TW, P. (1992). The p300 wave of the human event-related potential.
- W., W. (2012). A fast and reliable method for simultaneous waveform, amplitude and latency estimation of single-trial eeg/meg data. *Plosone*.
- Zisk A., Borgheai S., M. J. D. R. (2021). Improving longitudinal p300-bci performance for people with als using a data augmentation and jitter correction approach. *Taylor and Francis Online*.